

Relatório completo

"Investigue como a IA generativa está transformando o processo de pesquisa científica, da formulação de hipóteses à publicação. Compare evidências recentes sobre benefícios, limitações e riscos, identifique resultados contraditórios e lacunas ainda existentes na literatura, utilizando estudos científicos publicados entre 2020 e 2026." *Generated by LeapSpace, Wed Sep 23 2026*

IA generativa e a transformação da pesquisa científica (2020-2026): insights rápidos

Tabela de achados-chave

Etapas do processo científico	Benefícios mais bem sustentados	Limitações/riscos principais	Grupos/contextos observados	Citações
Formulação de hipóteses	LLMs conseguem propor hipóteses plausíveis e testáveis e apoiar ideação inicial [1] [2]	Falta comparação robusta contra ideação humana sem IA; há sinais de viés conservador contra propostas mais novas [3] [4]	Evidência concentrada em estudos de viabilidade e avaliações por especialistas [2] [4]	[1] [2] [3] [4]
Revisão de literatura e síntese	Melhor evidência em triagem de título/resumo, alguma extração estruturada e redução substancial de carga manual [5] [6]	Busca autônoma e síntese completa seguem fracas; modelos podem perder 68%-96% dos estudos na busca e errar em risco de viés [7]	Revisões sistemáticas, sobretudo biomédicas e em saúde [8] [9]	[5] [6] [7] [8] [9]
Desenho de estudo, análise e código	Apoio a estruturação de perguntas, rotulagem, exploração de parâmetros e geração/refatoração de código com ganho de tempo [10] [11] [12]	Evidência empírica ainda fragmentada; qualidade depende de validação especializada e testes [13] [14]	Estudos de caso em engenharia, ALD, programação científica e fluxos laboratoriais [10] [11] [12]	[10] [11] [12] [13] [14]
Redação de manuscritos	Textos mais claros, legíveis e rápidos de produzir; feedback automatizado pode ser útil e veloz [15] [16] [17]	Trade-off recorrente: melhor forma textual, mas menor precisão técnica e profundidade [16] [18] [19]	Manuscritos simulados, escrita acadêmica e grupos de estudantes/pesquisadores [20] [21]	[15] [16] [17] [18] [19] [20]
Revisão por pares e publicação	Útil para triagem, checagens padronizadas e feedback preliminar [22] [23]	Não reproduz bem julgamento humano sobre originalidade, interpretação e aplicabilidade; preocupa confidencialidade [24] [25] [26]	Uso editorial e de revisão ainda restrito e politicamente sensível [27] [28]	[22] [23] [24] [26]
Governança e integridade	Convergência em disclosure, proibição de IA como autora e responsabilidade humana final [29] [30]	Políticas heterogêneas e aplicação inconsistente; lacunas para uso por revisores [28] [29]	Editoras, periódicos e instituições acadêmicas [29] [31]	[28] [29] [30] [31]

Riscos transversais	RAG e fluxos decompondo tarefas reduzem alucinações e melhoram rastreabilidade [32] [33] [34]	Referências fabricadas, erro factual, documentação incompleta, viés e desigualdade de acesso permanecem frequentes [35] [36] [37]	Biomedicina, escrita científica, QA e adoção institucional/global [33] [38]	[32] [33] [34] [35] [36] [37] [38]
---------------------	---	---	---	------------------------------------

Resposta direta

Entre 2020 e 2026, a IA generativa transformou a pesquisa científica sobretudo como **copiloto cognitivo**, não como substituta do pesquisador [39] [40] [41] [42]. A evidência mais sólida favorece usos **estruturados e verificáveis**: triagem de revisões, extração preliminar, rascunho e polimento textual, feedback de manuscritos e assistência de código, frequentemente com grande economia de tempo e desempenho aceitável quando há supervisão humana [5] [6] [10] [11] [15] [17]. Já tarefas abertas que exigem **julgamento científico**, como busca bibliográfica autônoma, síntese interpretativa, avaliação de risco de viés, revisão por pares profunda e decisão editorial, continuam instáveis e propensas a erro [7] [9] [24] [25].

Na formulação de hipóteses, os resultados são promissores, mas ainda não conclusivos: LLMs conseguem sugerir ideias plausíveis e testáveis, porém não há demonstração robusta de superioridade sobre pesquisadores sem IA em novidade, testabilidade ou sucesso experimental downstream [1] [2] [3] [4]. Na escrita científica, aparece a contradição central da literatura: a IA costuma melhorar clareza e velocidade, mas pode piorar precisão técnica e profundidade argumentativa [16] [18] [20]. Os riscos mais consistentes são alucinações, referências fabricadas, vieses, baixa transparência metodológica e ampliação de desigualdades entre pesquisadores e instituições [35] [37] [43] [44].

Tomadas em conjunto, as evidências sugerem que a transformação mais confiável não é “automatizar a ciência”, mas **reorganizar o fluxo científico em microtarefas auditáveis**, apoiadas por RAG, validação especialista, trilhas de auditoria e disclosure explícito [32] [33] [45] [46].

Confidence level: High - há convergência forte entre revisões, estudos comparativos e documentos metodológicos sobre benefícios assistivos, limites em tarefas abertas e necessidade de supervisão humana [17] [47] [48].

Escopo do estudo

Esta síntese cobre literatura publicada entre **2020 e 2026**, com foco em quatro frentes: formulação de hipóteses e revisão de literatura; desenho de estudo, análise e código; redação, revisão por pares e publicação; riscos, governança e desigualdade de adoção [2] [10] [22] [31]. Os métodos incluídos no material fornecido abrangem revisões sistemáticas, estudos comparativos, estudos de caso, análises de políticas editoriais, avaliações de tarefas específicas e meta-sínteses metodológicas [7] [9] [29] [49].

Pressupostos e limitações

A literatura disponível mede muito mais **eficiência de tarefa** do que **qualidade científica downstream**, como replicação, aceitação editorial real ou descoberta experimental bem-sucedida [10] [17] [50] [51]. Há forte concentração em biomedicina, revisões sistemáticas e escrita acadêmica, com menos evidência comparativa multicampo e longitudinal [9] [31]. Em várias frentes, sobretudo geração de hipóteses e produtividade editorial, os achados permanecem fragmentados e baseados em estudos de viabilidade ou simulações [3] [52].

Pesquisa futura sugerida

- Testes randomizados ou quase-experimentais comparando ideação humana, humano+IA e IA em novidade, testabilidade e validação experimental [3] [4].
- Estudos longitudinais sobre submissões, aceitação, retratações, tempo até publicação e impacto científico real [17] [52].
- Benchmarks padronizados para síntese de evidências complexa, incluindo causalidade, heterogeneidade e risk-of-bias [7] [9].
- Avaliações multicampo e multirregionais, especialmente fora da biomedicina e no Sul Global [37] [38] [53].
- Estudos sobre como treinamento do usuário, senioridade e infraestrutura institucional moderam benefícios e riscos [44] [54] [55].

1. Contexto fundacional: o que exatamente a IA generativa mudou na pesquisa

A literatura recente descreve a IA generativa, especialmente LLMs, como uma camada transversal que passou a atuar em várias etapas da pesquisa: recuperação e organização de literatura, formulação de hipóteses, apoio ao desenho do estudo, análise textual e computacional, redação, revisão e suporte editorial [39] [41]. O ponto central é que essa transformação não ocorreu como automação integral do método científico, mas como **assistência modular** em tarefas específicas [40] [42] [56].

Há uma distinção importante entre **automação parcial** e **substituição de tarefas**. A automação parcial aparece melhor sustentada em subtarefas estruturadas, como screening, extração preliminar, correção linguística, rotulagem e geração inicial de código [5] [6] [13] [57]. Já a substituição plena do pesquisador é repetidamente desaconselhada, porque os modelos ainda falham em rastreabilidade, julgamento causal, avaliação metodológica e confiabilidade factual [7] [14] [24] [35].

Tomadas em conjunto, essas evidências sugerem um deslocamento do trabalho científico para fluxos **humano-no-laço**, em que a IA acelera a primeira passagem e o humano valida, corrige e decide [31] [48] [58] [59].

Confidence level: High - a convergência entre áreas e tipos de estudo é forte nesse ponto [40] [41] [60] [61].

2. Panorama da transformação da pesquisa científica

2.1 Da busca de conhecimento ao apoio à decisão científica

Em revisões e artigos metodológicos, LLMs são apresentados como ferramentas para revisão de literatura, síntese de evidências, geração de hipóteses e redação, porém com melhor desempenho quando integrados a fluxos supervisionados [39] [40] [41]. Isso importa porque o valor não está apenas em “responder perguntas”, mas em **reduzir fricções cognitivas**: resumir literatura, estruturar tópicos, sugerir caminhos de busca ou reformular textos [1] [39] [56] [57].

Contudo, a passagem de “apoio à decisão” para “decisão científica” continua problemática. Sistemas generativos podem ajudar a organizar o espaço do problema, mas não substituem o raciocínio sobre validade interna, causalidade, generalização ou mérito científico [7] [25] [62]. Essa assimetria explica por que o uso mais robusto da IA ainda é assistivo [31] [40] [42].

2.2 Onde a IA agrega mais valor no fluxo de pesquisa

Os ganhos mais consistentes aparecem em tarefas delimitadas. Em triagem de revisões, ferramentas de IA evitaram entre 20% e 88% da triagem manual em alguns estudos, sem perder citações incluídas em certas configurações [5]. Em um fluxo full-text com LLM, relatou-se 82% de acurácia e 100% de recall em treino/seleção, com sensibilidade de validação de 91,4% [6]. Em extração, os melhores usos são como rascunho inicial depois verificado por humanos [63] [64].

Na escrita, GenAI melhora polimento, legibilidade e feedback [15] [16]. Em programação científica, há relatos de ganhos de eficiência com validação por testes de código [11]. O padrão é claro: quanto mais a tarefa puder ser definida por critérios explícitos, mais estável tende a ser o benefício [6] [11] [15].

Confidence level: High - há evidência comparativa direta em screening, escrita e apoio a código, embora nem sempre com métricas homogêneas [5] [17].

3. Formulação de hipóteses, revisão e desenho de estudos

3.1 Geração de hipóteses e avaliação de novidade

A literatura é favorável quanto à **plausibilidade** das hipóteses geradas por LLMs, mas não quanto à sua superioridade científica. ChatGPT foi descrito como capaz de estruturar conhecimento e produzir hipóteses consideradas interessantes e testáveis, porém com alta taxa de erro e sem comparação controlada com ideação humana sem IA [1]. Uma revisão sistemática de 2026 concluiu que LLMs podem apoiar hipóteses valiosas e que alguns casos foram verificados experimentalmente, mas enfatizou gargalos em alucinação e raciocínio [2].

O resultado mais importante e menos favorável é o estudo em avaliação de propostas, no qual GPT-4o mostrou menor propensão do que humanos a financiar propostas mais novas, sugerindo viés conservador [3]. Isso enfraquece a narrativa de que a IA necessariamente ampliaria originalidade. Em estudos de ideação, ganhos dependem também da experiência do pesquisador: usuários mais experientes tendem a incorporar menos as sugestões e obter menores ganhos marginais em novidade e impacto [54].

Resultado contraditório: a IA parece ajudar a gerar ideias iniciais, mas pode favorecer propostas mais convencionais quando o julgamento exige sensibilidade para novidade [3] [54].

Confidence level: Medium - há sinais consistentes, mas faltam comparações head-to-head com métricas downstream robustas [4].

3.2 Síntese de evidências e revisão de literatura

Aqui a literatura é mais madura. A etapa com melhor desempenho é screening. Em câncer, Abstrackr evitou 20%-88% da triagem de título/resumo, EPPI-Reviewer 38% e DistillerSR 42%, sem perda de estudos incluídos em certos cenários [5]. Há também estudos de fluxos híbridos calibrados por humanos com AUC preditiva alvo $\geq 0,98$ [8].

Mas o desempenho cai fortemente quando a tarefa se desloca para **busca autônoma** e **síntese aberta**. Uma revisão sistemática de 2025 relatou que GenAI perdeu 68%-96% dos estudos na busca, além de erros de 10%-56% em avaliação de risco de viés [7]. Meta-revisões também mostram que apenas pequena parcela dos estudos aborda automação avançada de síntese, heterogeneidade ou bias assessment [9].

Na extração, o uso mais seguro segue sendo “primeira passada” sujeita a checagem manual [63] [65]. Em outras palavras, a IA acelera o pipeline de revisão, mas não valida sozinha o produto final [66] [67].

3.3 Desenho experimental, análise e apoio a código

Os dados aqui são mais fragmentados. Um estudo de caso em engenharia mostrou que a GenAI produziu saídas de design mais rápidas, amplas e focadas, mas exigiu refinamento manual porque inferências não examinadas podiam tornar os resultados irrelevantes [10]. Em rotulagem em larga escala, ChatGPT 4o alcançou 99,5% de precisão com validação por especialistas, sugerindo viabilidade como assistente, não como substituto [13].

Em contextos laboratoriais e experimentais, modelos generativos podem apoiar exploração de espaço paramétrico, seleção de variáveis e otimização, desde que haja verificação prospectiva e restrições físicas explícitas [12]. No apoio a código, há relatos de maior eficiência com uso de Claude Sonnet 4 via GitHub Copilot, mas a confiabilidade foi checada com testes de caso, o que reforça a necessidade de validação [11].

Inferred: Taken together, these findings suggest que a utilidade da IA em desenho e análise cresce quando os objetivos podem ser operacionalizados em verificações externas claras, como precisão de rótulo, teste de código ou validação experimental restrita [11] [12] [13].

Confidence level: Medium - a direção é consistente, mas a base empírica ainda é composta majoritariamente por estudos de caso e avaliações locais [10].

4. Escrita, revisão por pares e publicação

4.1 Redação, revisão e melhoria de manuscritos

Na escrita científica, a evidência é mista, mas informativa. Em estudo sobre feedback de manuscritos, ferramentas GenAI produziram comentários mais eficazes e mais rápidos do que revisores humanos em critérios como relevância, completude, acurácia e capacidade construtiva [15]. Em comparação de manuscritos, a versão escrita por IA teve melhor clareza e legibilidade, mas pior precisão técnica e profundidade [16].

Outro estudo com instrumento validado observou melhora de estilo e legibilidade em artigos pós-2024, sem melhora correspondente em acurácia ou coesão [68]. Já avaliações orientadas à prontidão editorial mostraram que GenAI pode pontuar bem em ferramentas como CLEAR e ainda assim divergir das decisões de editores humanos [18].

Portanto, o benefício textual é real, mas ele não equivale a melhor ciência.

Confidence level: High - os achados convergem fortemente no trade-off entre forma e substância [16] [18] [20].

4.2 Produtividade e diferenças por perfil do autor

Experimentos e estudos simulados relatam grandes reduções de tempo. ChatGPT reduziu em média 40% o tempo de escrita em experimento com 453 profissionais e elevou a qualidade em 18% [17]. Em estudo de manuscrito simulado, versões com IA reduziram o tempo em cerca de 84% em relação à escrita humana, e a versão combinada humano+IA teve melhor qualidade avaliada por especialistas [20].

Mas os efeitos não são uniformes. Há estudos associando uso de IA a maior produtividade em áreas aplicadas e entre pesquisadores seniores, mas menor produtividade entre juniores [55]. Em estudantes, houve ganhos moderados em qualidade percebida e confiança, enquanto habilidades de ordem superior, como argumentação disciplinar, melhoraram pouco [21].

Resultado contraditório: a IA acelera a produção textual, mas isso não garante melhora equivalente em competências científicas avançadas nem benefícios iguais entre níveis de experiência [21] [55].

Confidence level: Medium - há bons dados de tempo e qualidade imediata, mas pouca evidência sobre produtividade bibliométrica real [52].

4.3 Revisão por pares, triagem editorial e limites institucionais

A IA pode imitar a forma da revisão por pares e gerar volume útil de comentários iniciais [69] [70]. Também pode apoiar triagem editorial, checagens padronizadas e detecção de problemas metodológicos ou estruturais [22] [23]. Porém, comparações diretas mostram que revisões por IA são mais focadas em formato, menos detalhadas e menos diversas tematicamente do que revisões humanas; humanos superam a IA em interpretação, originalidade e aplicabilidade [24].

Além disso, revisões geradas por IA tendem a ser mais lenientes, menos propensas a recomendar rejeição e fracamente alinhadas às decisões editoriais humanas [25] [71]. Em paralelo, editoriais e análises de política desencorajam o uso formal de IA em peer review por problemas de confidencialidade, accountability e risco factual [26] [72].

Conclusão prática: IA é útil como **pré-revisor técnico**, mas não como revisor substantivo final [23] [24].

Confidence level: High - há forte convergência entre evidência empírica e posição normativa [24] [26] [73].

4.4 Políticas de publicação, autoria e disclosure

As políticas permanecem heterogêneas. Em 2023-2026, muitas editoras e periódicos ainda tinham regras inconsistentes ou de difícil acesso, e algumas políticas de periódicos conflitavam com as de suas próprias editoras [29]. Ainda assim, alguns princípios se repetem: IA não deve ser autora [29] [30]; uso de IA deve ser divulgado com transparência [30] [74]; e a responsabilidade pelo conteúdo permanece humana [30] [75].

As regras para revisores ainda são menos desenvolvidas do que para autores, com pedidos explícitos por procedimentos transparentes e sanções para violações [28] [76].

Confidence level: High - a governança é fragmentada, mas os princípios centrais mostram convergência clara [29] [31].

5. Riscos, contradições e lacunas

5.1 Alucinações, citações fabricadas e erro factual

Este é o risco mais quantificado da literatura. Em referências científicas e médicas geradas por ChatGPT, 47% de 115 referências foram totalmente fabricadas, 46% tinham detalhes incorretos e apenas 7% eram autênticas e corretas [35]. Outro estudo encontrou 69 de 178 referências sem DOI válido e 28 não localizáveis [35]. Comparações entre versões de modelos sugerem melhora parcial, mas não confiabilidade suficiente para uso sem checagem [77] [78].

Em contraste, sistemas com recuperação de evidências reduziram fortemente as alucinações. Em odontologia/implantodontia, sistemas retrieval-augmented eliminaram citações fabricadas, enquanto modelos generativos convencionais produziam referências e estatísticas inventadas [33]. Em QA em saúde pública, RAG reduziu alucinações em mais de 40% [34].

5.2 Reprodutibilidade, rastreabilidade e transparência

Fluxos assistidos por IA são mais reproduzíveis quando documentam versão do modelo, prompts completos, parâmetros como temperatura, data de geração, materiais de entrada, configuração da ferramenta e registros de validação [36] [46] [79] [80]. Mas a literatura mostra baixa disponibilidade de dados e código em muitos trabalhos de IA, além de fraca documentação de procedência, fontes recuperadas e protocolos de avaliação [43] [81] [82].

Em vários estudos, a limitação mais séria para verificação não é o desempenho bruto do modelo, e sim a impossibilidade de reconstruir como a saída foi produzida [83] [84].

5.3 Viés, desigualdade e acesso desigual

Os benefícios da IA generativa distribuem-se desigualmente. Pesquisadores e instituições com mais recursos têm maior acesso a ferramentas premium, suporte e treinamento, enquanto usuários com menos recursos dependem mais de versões gratuitas, smartphones ou gasto pessoal [38] [44]. Estudos também apontam disparidades entre Norte Global e Sul Global: em certos contextos do Sul, GenAI aparece menos como conveniência e mais como necessidade para acessar pesquisa fechada e compensar fragilidades institucionais [37] [53].

A literatura ainda subexamina diferenças por gênero, raça, idioma, deficiência e estratificação socioeconômica, mas já as aponta como riscos relevantes [85] [86] [87].

5.4 Contradições centrais da literatura

Quatro contradições sobressaem:

1. **Mais velocidade, não necessariamente melhor ciência** [17] [50].
2. **Melhor clareza textual, às vezes pior precisão técnica** [16] [18].
3. **Desempenho forte em microtarefas fechadas, fraco em síntese aberta e julgamento metodológico** [6] [7] [24].
4. **Ganhos heterogêneos por senioridade, disciplina e infraestrutura** [37] [44] [55].

Confidence level: High - essas contradições aparecem de forma repetida e transversal no conjunto de estudos [7] [16] [17] [37].

6. O que a literatura ainda não resolve

A lacuna mais importante é a ausência de evidência sólida sobre **impacto downstream em descoberta científica**. Ainda são raros estudos comparando, de forma causal, hipóteses geradas por humanos, humano+IA e IA quanto a novidade, testabilidade e sucesso experimental posterior [3] [4]. Também faltam estudos longitudinais sobre aceitação editorial, retratações, impacto bibliométrico e qualidade metodológica independente [17] [52].

Outra lacuna é a ausência de benchmarks padronizados multicampo para síntese complexa, risco de viés, integração interpretativa e workflows RAG versus chat puro [9] [31]. Além disso, muitos artigos deixam de relatar prompts, versão do modelo, configurações e fontes recuperadas, o que limita a cumulatividade da própria literatura sobre IA [36] [82] [88].

Confidence level: High - a crítica metodológica é amplamente compartilhada nas revisões e documentos de orientação [47] [48].

7. Conclusão

A melhor leitura da literatura entre 2020 e 2026 é que a IA generativa está **acelerando** a pesquisa científica mais do que **automatizando** a ciência [5] [17] [39]. Seu valor empírico é mais convincente em tarefas estruturadas, auditáveis e passíveis de validação externa, como screening, extração preliminar, polimento de texto e apoio a código [5] [11] [15] [63]. Seu desempenho piora quando a tarefa exige interpretação substantiva, originalidade, julgamento metodológico e responsabilidade editorial [7] [24] [25].

A principal implicação prática é que instituições, periódicos e grupos de pesquisa deveriam migrar do uso informal de chatbots para **pipelines controlados**, com RAG, decomposição em subtarefas, especialista no circuito, documentação de prompts/versões e disclosure explícito [32] [33] [45] [46]. Isso não elimina os riscos, mas alinha o uso da IA com o que a evidência atual sustenta.

Conclusão geral - Confidence level: High - a síntese é robusta quanto ao padrão macro: ganhos de eficiência assistiva, fragilidade em julgamento aberto, riscos recorrentes de integridade e necessidade de governança humana [26] [31] [47]. **Confidence level: Medium** quanto ao impacto da IA sobre descoberta científica real e produtividade editorial de longo prazo, porque a literatura ainda mede mais tarefas intermediárias do que resultados científicos finais [4] [52].

References

1. Park, Y.J., Kaplan, D., Ren, Z., (...), Li, J. (2024) Can ChatGPT be used to generate scientific hypotheses?. *Journal of Materiomics*. <https://doi.org/10.1016/j.jmat.2023.08.007>
2. Yuan, C., Ziyue, L., Yuanbo, K., Le, L. (2026) A Survey of Large Language Model-Driven Scientific Hypothesis Generation. *Data Analysis and Knowledge Discovery*. <https://doi.org/10.11925/infotech.2096-3467.2026.0133>
3. Machado, D. (2026) Generative AI bias against scientific novelty: a cautionary tale from a small-sample evaluation of research proposals. *Scientometrics*. <https://doi.org/10.1007/s11192-026-05792-x>
4. Xu, R., Sun, Y., Ren, M., (...), Han, X. (2024) AI for social science and social science of AI: A survey. *Information Processing and Management*. <https://doi.org/10.1016/j.ipm.2024.103665>
5. Yao, X., Kumar, M.V., Su, E., (...), Sussman, J. (2024) Evaluating the efficacy of artificial intelligence tools for the automation of systematic reviews in cancer research: A systematic review. *Cancer Epidemiology*. <https://doi.org/10.1016/j.canep.2023.102511>

6. Ye, Yongxin, Colombo, Martina, Meessen, Jennifer, (...), Tyl, Benoit (2026) Automated full-text screening and accelerated reviews using large language models with context-aware agents: an exploratory analysis in biomarker research. *European Heart Journal - Digital Health*. <https://doi.org/10.1093/ehjdh/ztag070>
7. <https://www.sciencedirect.com/science/article/pii/S1759288725000371>
8. <https://www.sciencedirect.com/science/article/pii/S2234943X26034202>
9. <https://www.sciencedirect.com/science/article/pii/S175928872600002X>
10. Naghdy, F. (2025) Collaboration with GenAI in engineering research design. *Data and Knowledge Engineering*. <https://doi.org/10.1016/j.datak.2025.102445>
11. Herrmann, Tim, Delbridge, Claire, Griessmair, Michael, (...), Metz, Marie-Christin (2026) The Spatial Signature of Glioblastoma: A Statistical Re-Assessment of Anatomical Distribution Based on Methylation Subtypes. *Cells*. <https://doi.org/10.3390/cells15020175>
12. Ampadi Ramachandran, R., Navabi, P., Jaber-Douraki, M., (...), Takoudis, C.G. (2026) Advancing atomic layer deposition through artificial intelligence: Generative modeling and predictive analytics for TiO₂ growth rate prediction from TDMAT/O₃. *Surface and Coatings Technology*. <https://doi.org/10.1016/j.surfcoat.2026.133341>
13. Nielsen, S.B., Sutter, A., Bourgeois, I., (...), Lemire, S. (2026) How to train a work horse: Using generative AI for labelling data. *From Algorithms to Evidence: Using GenAI in Evaluation Practice*. <https://doi.org/10.4324/9781003799139-13>
14. Álvarez-Martínez, Francisco Javier, Esteban, Luis, Frungillo, Lucas, (...), Barraji n-Catal n, Enrique (2025) There are significant differences among artificial intelligence large language models when answering scientific questions. *Frontiers in Artificial Intelligence*. <https://doi.org/10.3389/frai.2025.1664303>
15. Lim, G.H., Tan, M.L., Hoe, V.C.W., Koh, D. (2025) Generative AI in peer review process for occupational health. *Occupational Medicine*. <https://doi.org/10.1093/occmed/kqaf051>
16. Nathani, K.R., Nathani, A.-M., Delawan, M., (...), Bydon, M. (2025) Can artificial intelligence write science? A comparative analysis of human-written and artificial intelligence-generated scientific writings. *Journal of Neurosurgery: Spine*. <https://doi.org/10.3171/2025.4.SPINE25519>
17. Noy, S., Zhang, W. (2023) Experimental evidence on the productivity effects of generative artificial intelligence. *Science*. <https://doi.org/10.1126/science.adh2586>
18. Sallam, M., Al-Mahzoum, K., Marzooq, O., (...), Barakat, M. (2024) Evident gap between generative artificial intelligence as an academic editor compared to human editors in scientific publishing. *Edelweiss Applied Science and Technology*. <https://doi.org/10.55214/25768484.v8i6.2189>

19. Meng, Q., Xie, Y.-N., Lu, D. (2026) A systematic review of AI-assisted academic writing: Tools, measures, and effects. *Journal of English for Academic Purposes*.
<https://doi.org/10.1016/j.jeap.2026.101726>
20. Giavina-Bianchi, M., D'adario, A., Giavina Bianchi, P., Machado, B.S. (2025) Three versions of an atopic dermatitis case report written by humans, artificial intelligence, or both: Identification of authorship and preferences. *Journal of Allergy and Clinical Immunology: Global*. <https://doi.org/10.1016/j.jacig.2024.100373>
21. Nguyen, P.B.T., Tran, N.B.C. (2026) AI-supported tools for English Academic Writing and Publishing: A Case Study of Vietnamese Biotechnology Undergraduates. *Arab World English Journal*. <https://doi.org/10.24093/awej/vol17no1.27>
22. Nabavi, A., Safari, F., Shmoury, A.H., (...), Celi, L.A. (2026) Artificial intelligence in scholarly peer review: a scoping review of applications, risks, and governance challenges. *International Journal of Medical Informatics*. <https://doi.org/10.1016/j.ijmedinf.2026.106418>
23. Grice, Adam, Dambha-Miller, Hajira (2024) The future of peer review: an editorial. *BJGP Open*. <https://doi.org/10.3399/BJGPO.2024.0285>
24. Rajakumar, Hamrish Kumar, Sankaran, Kailash Abhishek, Ashok, Manasi Pillai, Rachoori, Srinivas (2026) Peer review in the age of artificial intelligence: a comparative study of human and AI-generated review reports. *Postgraduate Medical Journal*.
<https://doi.org/10.1093/postmj/qgag005>
25. Nabavi, A., Safari, F., Shmoury, A.H., (...), Celi, L.A. (2026) Artificial intelligence in scholarly peer review: a scoping review of applications, risks, and governance challenges. *International Journal of Medical Informatics*. <https://doi.org/10.1016/j.ijmedinf.2026.106418>
26. Doskaliuk, B., Zimba, O., Yessirkepov, M., (...), Yatsyshyn, R. (2025) Artificial Intelligence in Peer Review: Enhancing Efficiency While Preserving Integrity. *Journal of Korean Medical Science*. <https://doi.org/10.3346/jkms.2025.40.e92>
27. <https://www.sciencedirect.com/science/article/pii/S1421983226000219>
28. Mollaki, V. (2024) Death of a reviewer or death of peer review integrity? the challenges of using AI tools in peer reviewing and the need to go beyond publishing policies. *Research Ethics*. <https://doi.org/10.1177/17470161231224552>
29. Ganjavi, C., Eppler, M.B., Pekcan, A., (...), Cacciamani, G.E. (2024) Publishers' and journals' instructions to authors on use of generative artificial intelligence in academic and scientific publishing: Bibliometric analysis. *BMJ*. <https://doi.org/10.1136/bmj-2023-077192>
30. Hosseini, M., Resnik, D.B., Holmes, K. (2023) The ethics of disclosing the use of artificial intelligence tools in writing scholarly manuscripts. *Research Ethics*.
<https://doi.org/10.1177/17470161231180449>

31. Dwivedi, Y.K., Kshetri, N., Hughes, L., (...), Wright, R. (2023) "So what if ChatGPT wrote it?" Multidisciplinary perspectives on opportunities, challenges and implications of generative conversational AI for research, practice and policy. *International Journal of Information Management*. <https://doi.org/10.1016/j.ijinfomgt.2023.102642>
32. Wang, Zifeng, Cao, Lang, Danek, Benjamin, (...), Sun, Jimeng (2025) Accelerating clinical evidence synthesis with large language models. *npj Digital Medicine*. <https://doi.org/10.1038/s41746-025-01840-7>
33. Hosseini Hooshir, M.H. (2026) Artificial intelligence reliability in implant dentistry: A comparative analysis of clinical accuracy and hallucination patterns across multiple language models. *Journal of Prosthetic Dentistry*. <https://doi.org/10.1016/j.prosdent.2025.11.005>
34. Caliman-Sturdza, Olga Adriana, Gheorghita, Roxana Elena, Filip, Roxana, Lobiuc, Andrei (2026) Artificial Intelligence in Infectious Disease Care: Selected Applications in Tuberculosis, Sepsis, and Antimicrobial Stewardship. *Diagnostics*. <https://doi.org/10.3390/diagnostics16121827>
35. Boretti, A. (2026) Hallucinations in generative AI: A threat to scholarly integrity and the urgent need for publisher-led academically supervised verification. *Energy Research and Social Science*. <https://doi.org/10.1016/j.erss.2026.104720>
36. Gong, Eun Jeong, Bang, Chang Seok, Shin, Yong Seok (2026) Applications of Large Language Models in Medical Research: From Systematic Reviews to Clinical Studies. *Bioengineering*. <https://doi.org/10.3390/bioengineering13030365>
37. Olaniyan, Y.D., Martins, M.O., Al Maqrashi, R.H. (2026) Generative artificial intelligence and epistemic (in)justice: perspectives from higher education students in the Global North and South. *Frontiers in Human Dynamics*. <https://doi.org/10.3389/fhumd.2026.1790324>
38. Valdivieso, T., González, O. (2025) Generative AI Tools in Salvadoran Higher Education: Balancing Equity, Ethics, and Knowledge Management in the Global South. *Education Sciences*. <https://doi.org/10.3390/educsci15020214>
39. El Hari, E.H., Slimani, S. (2025) LLMs and Generative AI for the Detection and Generation of Scientific Content. *2025 International Conference on Circuit, Systems and Communication, ICCSC 2025*. <https://doi.org/10.1109/ICCSC66714.2025.11134858>
40. Fleurence, R.L., Qureshi, R., Aggarwal, R., (...), Chhatwal, J. (2026) The Use of Generative Artificial Intelligence in Systematic Literature Reviews: A Rapid Review of the Literature. *Value in Health*. <https://doi.org/10.1016/j.jval.2026.06.012>
41. Lin, Z. (2023) Why and how to embrace AI such as ChatGPT in your academic life. *Royal Society Open Science*. <https://doi.org/10.1098/rsos.230658>

42. Celik, S.U. (2025) Integrating artificial intelligence into scientific writing: a narrative review for clinical and surgical researchers. *American Journal of Surgery*.
<https://doi.org/10.1016/j.amjsurg.2025.116657>
43. Arefeen, Asiful, Singh, Simar, Razavi, Crystal, (...), Dev, Sandesh (2025) Assessing the quality of reporting in artificial intelligence/machine learning research for cardiac amyloidosis. *JAMIA Open*. <https://doi.org/10.1093/jamiaopen/ooaf104>
44. Cabras, A., Marra, M., Capasso, G., (...), Costanzo, S. (2026) Adoption of generative AI at the Italian institute for astrophysics: a survey on usage trends, ethics, literacy, and Shadow IT. *Frontiers in Astronomy and Space Sciences*. <https://doi.org/10.3389/fspas.2026.1829012>
45. Pickard, Joshua, Prakash, Ram, Choi, Marc Andrew, (...), Rajapakse, Indika (2025) Automatic biomarker discovery and enrichment with BRAD. *Bioinformatics*.
<https://doi.org/10.1093/bioinformatics/btaf159>
46. Miola, M., Cabiddu, D., Pittaluga, S., (...), Zuccolini, M. (2026) EWoPe: A light Embeddable WOrkflow PEristence tool for geoscientific pipeline reproducibility. *Computers and Geosciences*. <https://doi.org/10.1016/j.cageo.2025.106099>
47. Justin Clark, Belinda Barton, Loai Albarqouni, (...), Mark Jones (2025) Generative artificial intelligence use in evidence synthesis: A systematic review. *Research Synthesis Methods*.
<https://doi.org/10.1017/rsm.2025.16>
48. Jay, M., Abi-Jaoude, J., Straus, S.E., (...), Yu, C. (2026) Moving towards acceleration with accountability: a conceptual framework for AI-assisted systematic reviews. *Global Epidemiology*. <https://doi.org/10.1016/j.gloepi.2026.100282>
49. Jayasuriya, A.C., Skie, M. (2026) Use of artificial intelligence and radiomics for diagnosis and prediction of osteoporotic fractures: a systematic review. *Clinical Radiology*.
<https://doi.org/10.1016/j.crad.2026.107308>
50. Cifuentes-González, C., Singer, M.B., Rojas-Carabali, W., (...), Agrawal, R. (2026) Transforming Systematic Reviews: Evaluating a Fine-Tuned Large Language Model for Abstract Screening in Uveitis and Retinal Vasculitis. *Ophthalmology Science*.
<https://doi.org/10.1016/j.xops.2026.101296>
51. Bressane, A., de Castro, M.V., Nomura, L.M.N., Ewbank, H. (2026) Corporate environmental intelligence as an emerging governance framework in digital sustainability: A scoping review. *Environmental Development*. <https://doi.org/10.1016/j.envdev.2026.101467>
52. Vadner, D.J., Brown, A.N., Gold, M.H. (2026) Artificial Intelligence in medical research and publishing: Progress, risks, and future perspectives. *Presse Medicale*.
<https://doi.org/10.1016/j.lpm.2026.104371>

53. Schulz, M.S., Tavera-Fenollosa, L., Dussauge-Laguna, M.I., (...), Andersen, J.P. (2026) The uses of generative artificial intelligence in social research north and south: Comparing empirical evidence from surveys in Denmark and Mexico. *Methodological Innovations*. <https://doi.org/10.1177/20597991261454555>
54. Tröbinger, M., Doshi, A.R., Chai, S. (2026) How experience moderates the impact of AI suggestions on researchers' perceptions of their ideas. *Research Policy*. <https://doi.org/10.1016/j.respol.2026.105575>
55. Muscio, Alessandro, Shibayama, Sotaro (2026) Artificial intelligence in academic research: Adoption, productivity, and skill perceptions. *Technology in Society*. <https://doi.org/10.1016/j.techsoc.2026.103536>
56. Korinek, A. (2023) Generative AI for Economic Research: Use Cases and Implications for Economists⁺. *Journal of Economic Literature*. <https://doi.org/10.1257/jel.20231736>
57. Wang, Z., Lei, H., Chen, K. (2026) The influence of GenAI on second language writing instruction: A systematic review. *System*. <https://doi.org/10.1016/j.system.2026.104081>
58. Malik, F.S., Terzidis, O. (2026) A hybrid framework for creating artificial intelligence-augmented systematic literature reviews. *Management Review Quarterly*. <https://doi.org/10.1007/s11301-025-00522-8>
59. Pritting, S., Doran, P., Covington, H., (...), Sun, H. (2025) AI-Integrated Literature Discovery Tools: A Guide to Reviewing for Institution Wide Use. *Journal of Electronic Resources Librarianship*. <https://doi.org/10.1080/1941126X.2025.2497736>
60. Mabirizi, V., Katushabe, C., Muhoza, G., Rugasira, J. (2025) A systematic review of the impact of generative AI on postgraduate research: opportunities, challenges, and ethical implications. *Discover Artificial Intelligence*. <https://doi.org/10.1007/s44163-025-00495-3>
61. Mishra, T., Sutanto, E., Rossanti, R., (...), Zeeshan, B. (2024) Use of large language models as artificial intelligence tools in academic research and publishing among global clinical researchers. *Scientific Reports*. <https://doi.org/10.1038/s41598-024-81370-6>
62. Chen, J., Wang, H., Zhang, L. (2026) OptiSMR: A unified framework for structured reasoning and self-repairing multi-agent system optimized for generalization. *Knowledge-Based Systems*. <https://doi.org/10.1016/j.knosys.2026.116143>
63. Schiffman, J., Wislocki, K., Petti, E., (...), Mittal, V.A. (2026) Measuring Social and Role Recovery: Barbara Cornblatt and Colleagues' Global Functioning Scales and Their Role in Psychosocial Interventions for Clinical High-Risk and Early Psychosis. *Schizophrenia Bulletin*. <https://doi.org/10.1093/schbul/sbaf259>

64. Gartlehner, G., Kahwati, L., Hilscher, R., (...), Chew, R. (2024) Data extraction for evidence synthesis using a large language model: A proof-of-concept study. *Research Synthesis Methods*. <https://doi.org/10.1002/jrsm.1710>
65. Gawelczyk, Mateusz, Chycki, Jakub, Maszczyk, Adam, Zając, Adam (2026) Effects of Low-Carbohydrate and Ketogenic Diets on Anaerobic Performance in Competitive Athletes: A Systematic Review and Meta-Analysis. *Nutrients*. <https://doi.org/10.3390/nu18101589>
66. Fabiano, N., Gupta, A., Bhambra, N., (...), Solmi, M. (2024) How to optimize the systematic review process using AI tools. *JCPP Advances*. <https://doi.org/10.1002/jcv2.12234>
67. Messina, Rossella, Fantini, Maria Pia, Lodi, Michael, (...), Lenzi, Jacopo (2025) Patient-Reported Outcome Measures in Adults with Type 2 Diabetes—With a Focus on Older Populations: An AI-Assisted Rapid Review of Use and Implementation in Clinical and Organizational Practice. *Healthcare*. <https://doi.org/10.3390/healthcare13222840>
68. Pattier, D. (2025) Are we reading the researchers or the artificial intelligence? Transformations in academic writing after the expansion of generative AI*. *Praxis Educativa*. <https://doi.org/10.5212/PraxEduc.v.21.26223.031>
69. Hussein, A., Montaser, H., Smith, K. (2026) Efficient peer review via a fairness-aware priority mechanism: Game theoretic modelling and evaluation. *Journal of Informetrics*. <https://doi.org/10.1016/j.joi.2026.101856>
70. Moshirfar, Majid, Han, Kenneth D., Jaafar, Muhammed A., (...), Hoopes, Phillip C. (2026) Current capabilities of large language models as peer reviewers for manuscripts submitted to ophthalmology-related journals. *Medicine (United States)*. <https://doi.org/10.1097/MD.00000000000048147>
71. Mehmet Erturk, S.M., Durmaz, M. (2026) Large Language Models as Peer Reviewers: Prompt Sensitivity and Model-Dependent Reproducibility. *Academic Radiology*. <https://doi.org/10.1016/j.acra.2026.04.046>
72. van Zoonen, W., Morgan-Thomas, A., Tursunbayeva, A. (2026) Beyond AI disclosure: Claim accountability and responsible research in scholarly publishing. *European Management Journal*. <https://doi.org/10.1016/j.emj.2026.06.001>
73. Fedorchenko, Y., Usen, A., Seil, B., (...), Korkosz, M. (2026) Editorial policies for ethical use of artificial intelligence in rheumatology journals. *Seminars in Arthritis and Rheumatism*. <https://doi.org/10.1016/j.semarthrit.2026.152966>
74. Resnik, D.B., Hosseini, M. (2026) Disclosing artificial intelligence use in scientific research and publication: When should disclosure be mandatory, optional, or unnecessary?. *Accountability in Research*. <https://doi.org/10.1080/08989621.2025.2481949>

75. Stahl, B.C., Eke, D. (2024) The ethics of ChatGPT – Exploring the ethical issues of an emerging technology. *International Journal of Information Management*.
<https://doi.org/10.1016/j.ijinfomgt.2023.102700>
76. Zielinski, C., Winker, M.A., Aggarwal, R., (...), Habibzadeh, F. (2023) Chatbots, generative AI, and scholarly manuscripts: WAME recommendations on chatbots and generative artificial intelligence in relation to scholarly publications. *Colombia Medica*.
<https://doi.org/10.25100/cm.v54i3.5868>
77. Gong, Eun Jeong, Bang, Chang Seok, Shin, Yong Seok (2026) Applications of Large Language Models in Medical Research: From Systematic Reviews to Clinical Studies. *Bioengineering*.
<https://doi.org/10.3390/bioengineering13030365>
78. Uçar, Mahmut Talha, Bostan, Ecem, Dönmez, Elif, Cerit Soydan, Fatma (2026) Can Artificial Intelligence Support Patient Education in Scabies? A Comparative Analysis of Large Language Model Responses. *Healthcare*. <https://doi.org/10.3390/healthcare14101278>
79. Ang, Mia Yang, Chen, Li, Song, Lanni, (...), Choo, Siew Woh (2026) Responsible Use of Large Language Models in Microbial Genomics and Bioinformatics: A Life-Science Framework for Reliability, Reproducibility, and Risk-Aware Interpretation. *Life*.
<https://doi.org/10.3390/life16061032>
80. Zeman, Z., Mikkola, A., Orzechowski, G., (...), Mihola, M. (2026) Large language models in mechanical design of mechatronic systems: A review. *Advanced Engineering Informatics*.
<https://doi.org/10.1016/j.aei.2026.104807>
81. Kocak, B., Yardimci, A.H., Yuzkan, S., (...), Okumus, A.A. (2023) Transparency in Artificial Intelligence Research: a Systematic Review of Availability Items Related to Open Science in Radiology and Nuclear Medicine. *Academic Radiology*.
<https://doi.org/10.1016/j.acra.2022.11.030>
82. White, S.J., Yaxley, K.L., To, M.-S., Chau, M. (2026) Transparent reporting is central to reproducible radiological AI research: A call to action. *European Journal of Radiology*.
<https://doi.org/10.1016/j.ejrad.2026.112777>
83. Giuntelli, G., Spreafico, C., Precorvi, A., Russo, D. (2026) Patent intelligence in the age of AI: Unlocking strategic insights through granular classification. *World Patent Information*.
<https://doi.org/10.1016/j.wpi.2026.102454>
84. Sirago, G., Solarino, B., Dell’Erba, A., Ferorelli, D. (2026) Mapping 25 years of forensic and legal medicine research: a multi-database bibliometric and science-mapping analysis (2000–2025). *Journal of Forensic and Legal Medicine*.
<https://doi.org/10.1016/j.jflm.2026.103127>

85. Badran, N. (2025) Empowering Academic Libraries: AI Literacy, Ethics, and Skills. *2025 International Conference on Business Intelligence for Technology Innovation, ICBITI 2025*. <https://doi.org/10.1109/ICBITI65527.2025.11501083>
86. Li, M., Enkhtur, A., Yamamoto, B.A., (...), Chen, L. (2025) Potential Societal Biases of ChatGPT in Higher Education: A Scoping Review. *Open Praxis*. <https://doi.org/10.55982/openpraxis.17.1.750>
87. Ni, W., Li, J. (2026) Mapping the impact of generative AI in higher education: a scoping review of psychological and equity dimensions. *Frontiers in Psychology*. <https://doi.org/10.3389/fpsyg.2026.1856854>
88. Xin, H., Kitchin, J.R., López, N., (...), Zhang, Z. (2026) Transparent reporting for agentic catalysis enabled by artificial intelligence: Community guidelines and a publication checklist. *Chem Catalysis*. <https://doi.org/10.1016/j.checat.2026.101755>